Deep Learning GSLC – Part A: Analisis Konseptual

1. Efek Regularisasi pada Batch Normalization

Batch Normalization menormalisasi aktivasi pakai rata-rata μ_B dan varians σ_B^2 yang dihitung dari masing-masing mini-batch (Slide 7). Masalahnya, isi tiap batch selalu diacak ulang di setiap iterasi, jadi nilai μ_B dan σ_B^2 ini juga ikut berubah-ubah terus. Akibatnya, output untuk satu gambar ternyata ikut dipengaruhi oleh gambar lain yang kebetulan masuk di batch yang sama. Variasi kecil inilah yang jadi semacam noise. Karena ada noise ini, model jadi lebih susah menghafal data training mentah-mentah, dan dari situ muncul efek regularisasi ringan (Slide 8). Kata "often" di Slide 8 menurut saya penting, karena artinya Dropout tidak selalu bisa dibuang begitu saja. Ukuran batch juga berpengaruh: kalau batch terlalu kecil, statistiknya jadi kurang stabil dan training bisa kurang optimal. Kalau batch besar, statistiknya stabil, tapi noise-nya jadi sangat kecil sehingga efek regularisasinya juga hampir tidak terasa.

2. Degradasi Jaringan Dalam dan Formulasi Residual

Degradasi ini bukan overfitting. Buktinya, training error plain network 56 layer justru lebih tinggi daripada yang 20 layer [1], padahal kalau overfitting harusnya training error-nya lebih rendah. Slide 10 juga menyebut kalau network yang lebih dalam kadang malah hasilnya lebih jelek. Secara teori, layer tambahan cukup belajar identity mapping saja supaya performanya minimal sama, tapi ternyata optimizer kesulitan mendekati fungsi identitas lewat tumpukan layer non-linear [1]. Residual block mengakali ini dengan mengubah apa yang dipelajari: bukan $H(x)$ secara langsung, tapi $F(x) = H(x) - x$, dengan $H(x)$ sebagai mapping yang diinginkan, sehingga output-nya $y = F(x) + x$ (Slide 11). Kalau identity mapping memang yang terbaik, network tinggal mendorong $F(x)$ ke nol, dan itu jauh lebih gampang. Waktu backpropagation, gradiennya jadi $\partial L/\partial x = \partial L/\partial y \cdot (\partial F/\partial x + 1)$. Angka "+1" ini datang dari skip connection, dan fungsinya mengalirkan gradien langsung ke layer sebelumnya. Di Sesi 02 sudah dibahas bahwa vanishing gradient terjadi karena chain rule mengalikan banyak turunan yang kecil (disinggung juga di Slide 10). Dengan skip connection, gradien punya jalur aditif lewat +1, tidak cuma lewat perkalian, jadi layer-layer awal tetap dapat sinyal belajar yang cukup [2].

3. Feature Extraction vs. Fine-Tuning

Dari jumlah trainable parameter, bedanya jauh. Feature Extraction cuma melatih classifier head yang baru, yaitu 5.130 parameter di ResNet-18 untuk 10 kelas. Sementara itu, Fine-Tuning yang membuka layer4 dan fc melatih sekitar 8,4 juta parameter, kira-kira 75% dari total 11,2 juta. Karena yang dilatih sedikit, Feature Extraction lebih cocok kalau datanya terbatas (Slide 15). Fine-Tuning butuh data lebih banyak karena ada jutaan parameter yang dibuka, kalau tidak bakal gampang overfitting (Slide 28). Soal komputasi dan memori, Feature Extraction juga lebih ringan, karena backward pass dan state optimizer cuma dihitung untuk head, sedangkan Fine-Tuning harus menghitungnya untuk setiap layer yang dibuka. Risiko destructive gradient update juga cuma ada di Fine-Tuning: head baru yang bobotnya masih acak menghasilkan gradien besar, dan gradien ini bisa merusak fitur pretrained [3]. Jadi secara praktis, mulai dulu dari Feature Extraction (Slide 29). Kalau datanya cukup atau domainnya beda jauh dari ImageNet, baru pindah ke Fine-Tuning secara bertahap dengan learning rate kecil (Slide 16), karena fitur di layer-layer akhir sifatnya spesifik ke tugas aslinya [4].

4. Kaidah Penerapan Data Augmentation

Augmentasi cuma dipakai di train set, karena tujuannya memang untuk menambah variasi data latih supaya model lebih general (Slide 20). Validation dan test set fungsinya mengukur performa di data asli, jadi harus deterministik: cukup resize, center crop, dan normalisasi. Kalau data evaluasi ikut di-augmentasi secara acak, metriknya bakal beda-beda tiap run, early stopping yang memantau validation loss jadi tidak stabil, dan perbandingan antar eksperimen jadi tidak adil lagi. Augmentasi juga harus

dilakukan setelah data dibagi, secara on-the-fly di train set saja, supaya tidak terjadi data leakage. Contoh augmentasi yang tidak cocok untuk dataset pet breeds adalah ColorJitter yang mengubah hue (Slide 21 sendiri cuma menyebut brightness dan contrast). Augmentasi hanya aman kalau labelnya tetap benar [5], sedangkan warna bulu justru salah satu ciri pembeda ras. Misalnya, hue shift bisa bikin kucing Russian Blue yang bulunya abu-abu kebiruan kelihatan cokelat kemerahan seperti Abyssinian, padahal labelnya masih Russian Blue. Akhirnya model belajar dari pasangan gambar dan label yang salah.

5. Mitigasi Catastrophic Forgetting

Catastrophic forgetting terjadi kalau proses adaptasinya terlalu agresif, sampai pengetahuan lama dari pretraining tertimpa oleh tugas yang baru (Slide 28; [7]). Bobot pretrained sebenarnya sudah bagus untuk fitur-fitur umum dari ImageNet, tapi optimizer cuma peduli meminimalkan loss di data baru, dan tidak ada yang menahan bobot supaya tidak menjauh dari titik awalnya. Di awal fine-tuning, head yang baru masih acak sehingga gradiennya besar. Kalau learning rate-nya juga tinggi, gradien ini ikut menggeser bobot backbone dan merusak fitur pretrained [3]. Cara pertama untuk mengatasinya adalah differential learning rate: layer pretrained dikasih learning rate kecil (1e-4 untuk layer4), sedangkan head dikasih lebih besar (1e-3). Dengan begitu, fitur pretrained cuma bergeser sedikit, sementara head tetap bisa belajar dengan cepat (Slide 16). Cara kedua adalah gradual unfreezing: latih head dulu dengan backbone yang dibekukan (Slide 29), baru setelah itu buka layer-layer lainnya secara bertahap, karena layer terakhir menyimpan pengetahuan yang paling spesifik (Slide 16; [6]).

Deep Learning GSLC – Bagian C: Laporan dan Analisis

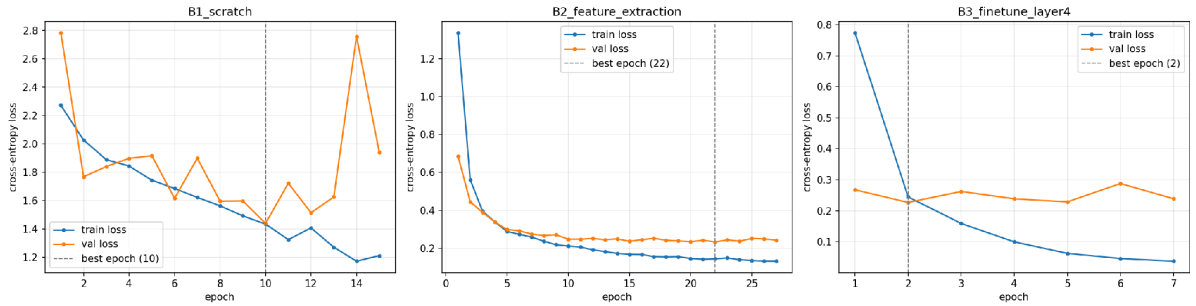
C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Semua eksperimen dijalankan di Google Colab (GPU Tesla T4) dengan seed 42, batch size 32, optimizer AdamW (weight decay 0,01), CrossEntropyLoss, maksimal 30 epoch, dan early stopping yang memonitor validation loss dengan patience 5. Dataset yang dipakai adalah subset 10 kelas Oxford-IIIT Pet, yaitu 5 ras kucing (Abyssinian, Bengal, Birman, Ragdoll, Russian Blue) dan 5 ras anjing (American Pit Bull Terrier, Staffordshire Bull Terrier, Beagle, Pug, Samoyed). Data dibagi secara stratified 70/15/15 menjadi 1.390 citra train, 298 validasi, dan 299 test. Dua pasang ras sengaja dipilih karena mirip secara visual (Birman–Ragdoll dan American Pit Bull Terrier–Staffordshire Bull Terrier) agar analisis kesalahan di C3 lebih bermakna.

Tabel 1. Konsolidasi hasil eksperimen B1–B5

Kode	Strategi	Trainable params	Learning rate	Epoch terbaik / total	Waktu (s)	Val acc	Test Macro F1
B1	ResNet-18 from scratch (dengan augmentasi)	11.181.642	semua: 1e-3	10 / 15	227,5	49,33%	45,91%
B2	Feature extraction (backbone beku, hanya fc)	5.130	fc: 1e-3	22 / 27	364,2	90,27%	88,85%
B3	Fine-tuning layer4 + fc, dengan augmentasi	8.398.858	layer4: 1e-4; fc: 1e-3	2 / 7	95,0	89,60%	90,29%
B4	Konfigurasi B3 tanpa augmentasi	8.398.858	layer4: 1e-4; fc: 1e-3	2 / 7	69,3	91,95%	90,45%
B5	EfficientNet-B0, fine-tuning features[7:9] + classifier, tanpa augmentasi	1.142.202 (dari 4.020.358)	features[7:9]: 1e-4; classifier: 1e-3	7 / 12	120,8	92,95%	94,95%

Catatan: waktu adalah total durasi training sampai early stopping berhenti. Augmentasi yang dipakai adalah RandomResizedCrop (scale 0,8–1,0), RandomHorizontalFlip, RandomRotation 15°, dan ColorJitter (brightness dan contrast saja, tanpa hue). Untuk B4, skenario "dengan augmentasi" adalah B3 itu sendiri. Konfigurasi B5 diambil dari run ResNet-18 dengan val accuracy tertinggi, yaitu B4.



Gambar 1. Kurva training loss vs. validation loss untuk B1, B2, dan B3 (garis putus-putus = epoch terbaik)

Validation loss B1 naik-turun tajam (terendah 1,44 di epoch 10, lalu melonjak ke 2,76 di epoch 14). Kurva B2 turun mulus dan mendatar di kisaran 0,23–0,25 sejak sekitar epoch 10. Pada B3, val loss sudah mencapai minimum 0,227 di epoch 2, sementara train loss terus turun hingga 0,037.

C2. Pembahasan Analisis Komparatif

1. Disparitas performa B1 vs. B2 & B3

Selisihnya sangat besar: Macro F1 B1 hanya 45,91%, sedangkan B2 dan B3 masing-masing 88,85% dan 90,29%, atau berbeda sekitar 43–44 poin. Ada dua penyebab utama. Pertama, B1 harus melatih 11,18 juta parameter dari bobot acak hanya dengan 1.390 citra, atau sekitar 139 citra per kelas. Residual connection (Slide 10–12) memang membantu gradien mengalir sehingga network yang dalam tetap dapat dioptimasi, tetapi tidak menyelesaikan masalah kurangnya data. Network tetap harus mempelajari semuanya dari nol, mulai dari edge dan tekstur hingga bentuk telinga atau pola bulu. Hal ini terlihat pada Gambar 1: validation loss B1 sangat tidak stabil, dan train accuracy di epoch terbaiknya hanya 49,93%. Jadi masalah B1 bukan sekadar overfitting, tetapi model belum sempat membentuk representasi yang baik sebelum early stopping berhenti di epoch 15. Kedua, model pretrained sudah membawa fitur umum dari ImageNet, yang juga memuat banyak kelas kucing dan anjing, sehingga head baru cukup belajar memetakan fitur yang sudah ada ke 10 kelas. Ini sesuai dengan prinsip transfer learning pada Slide 14–15: pengetahuan dari data skala besar digunakan kembali, bukan dibangun ulang dari awal.

2. Trade-off performa vs. stabilitas (B2 vs. B3)

B3 sedikit unggul dari B2 di test set (Macro F1 90,29% vs. 88,85%) dan jauh lebih cepat konvergen (epoch terbaik 2 vs. 22; total 95 vs. 364 detik). Namun validation loss terbaik keduanya hampir sama (0,227 vs. 0,234), dan selisih 1,4 poin di test set hanya setara sekitar 4–5 citra dari 299, sehingga keunggulan B3 sebenarnya tipis. Perbedaan yang lebih jelas ada pada stabilitas. B2 hanya melatih 5.130 parameter sehingga hampir tidak memiliki kapasitas untuk menghafal; kurvanya mulus dengan gap train-val accuracy 4,8 poin. Sebaliknya, B3 membuka 8,4 juta parameter, dan setelah epoch 2 train accuracy-nya terus naik hingga 99,1% sementara val loss berfluktuasi. Artinya B3 mulai menghafal train set tidak lama setelah titik terbaiknya, sehingga hasil akhirnya sangat bergantung pada early stopping. Differential learning rate (Slide 16) tetap menjaga fitur pretrained, terbukti val loss B3 tidak pernah melonjak seperti B1.

Waktu per epoch B2 dan B3 ternyata hampir sama (13–14 detik), kemungkinan karena forward pass tetap melewati seluruh backbone dan proses loading serta augmentasi data di CPU lebih dominan. Kesimpulannya, pada data sekitar 1.400 citra, fine-tuning bertahap memberi sedikit kenaikan performa dan konvergensi yang lebih cepat dengan risiko overfitting yang lebih tinggi, sedangkan feature extraction lebih stabil dan lebih aman bila tidak ada validation set yang andal.

3. Peran augmentasi dalam meredam overfitting (B4)

Gap train-val accuracy di epoch terbaik mengecil dari 5,1 poin (B4, tanpa augmentasi) menjadi 2,0 poin (B3, dengan augmentasi). Namun angka ini cenderung menyesatkan, karena train accuracy B3 diukur pada citra yang sudah di-augmentasi dan lebih sulit ditebak. Bila train accuracy diukur ulang dengan transform bersih, hasilnya 96,3% untuk B3 dan 99,9% untuk B4, sehingga gap terhadap validasi menjadi 6,7 poin vs. 8,0 poin. Jadi augmentasi memang meredam overfitting, tetapi efeknya lebih kecil daripada yang terlihat pada angka mentah. Efek yang paling jelas terlihat pada laju menghafal: tanpa augmentasi, train accuracy B4 sudah 100% di epoch 6 dengan train loss 0,005, sedangkan B3 masih 98,8% dengan train loss 0,046.

Meski begitu, test accuracy keduanya persis sama (90,64%), Macro F1 B4 sedikit lebih tinggi (90,45% vs. 90,29%), dan val accuracy B4 juga lebih tinggi (91,95% vs. 89,60%). Penjelasannya, kedua model mencapai epoch terbaik di epoch 2, sebelum overfitting sempat berpengaruh, sehingga early stopping menjadi regularisasi utama. Selain itu, layer1 sampai layer3 tetap beku sehingga fitur dasarnya sudah cukup robust terhadap variasi posisi dan pencahayaan. Augmentasi (Slide 20) kemungkinan baru berdampak nyata bila training berjalan lebih lama, lebih banyak layer yang dibuka, atau datanya lebih sedikit.

C3. Failure Analysis (Analisis Kasus Misklasifikasi)

Model terbaik berdasarkan val accuracy adalah B5 (EfficientNet-B0), yang salah memprediksi 15 dari 299 citra test. Pola kesalahannya sangat terkonsentrasi: 7 kesalahan terjadi antara American Pit Bull Terrier (APBT) dan Staffordshire Bull Terrier (SBT), 5 antara Birman dan Ragdoll, dan 3 sisanya adalah kucing yang diprediksi sebagai Abyssinian (2 Bengal dan 1 Russian Blue). Tidak ada kucing yang tertukar dengan anjing. Gambar 2 menampilkan 8 kesalahan dengan confidence tertinggi, dan hipotesis penyebabnya dirangkum pada Tabel 2.



Gambar 2. Delapan misklasifikasi dengan confidence tertinggi pada model B5

Tabel 2. Hipotesis penyebab kesalahan

No	Citra / Label asli	Prediksi (confidence)	Hipotesis penyebab
1	Birman_79.jpg / Birman	Ragdoll (98,6%)	Ambiguitas antar ras. Keduanya berbulu panjang dengan pola colorpoint. Ciri utama Birman, yaitu kaki putih seperti sarung tangan, tidak terlihat karena kucing berbaring dan kakinya tertutup.
2	Bengal_134.jpg / Bengal	Abyssinian (98,2%)	Bulu oranye hampir polos tanpa pola rosette yang jelas, sehingga lebih mirip warna ruddy Abyssinian. Foto juga buram dan beresolusi rendah. Ada kemungkinan label noise.
3	american_pit_bull_terrier_1.jpg / APBT	SBT (89,9%)	Pencahayaan ekstrem: sebagian tubuh terkena sinar langsung, sisanya gelap. Bulu brindle gelap membuat bentuk kepala dan otot sulit terbaca, ditambah latar belakang ruangan yang ramai.
4	american_pit_bull_terrier_26.jpg / APBT	SBT (89,1%)	Close-up kepala saja. Perbedaan utama kedua ras ada pada ukuran dan proporsi tubuh (APBT lebih tinggi dan ramping), yang tidak terlihat di foto ini.
5	american_pit_bull_terrier_98.jpg / APBT	SBT (83,4%)	Pose duduk dari depan sehingga tinggi dan panjang tubuh tidak dapat dinilai. Pola putih dengan patch hitam di kepala juga umum pada kedua ras.
6	Bengal_143.jpg / Bengal	Abyssinian (79,7%)	Close-up wajah, sedangkan tubuh tertutup selimut dan tangan pemilik (oklusi). Wajah hanya memperlihatkan garis tabby, bukan rosette khas Bengal. Model masih memberi 20% ke Bengal.
7	staffordshire_bull_terrier_62.jpg / SBT	APBT (72,2%)	Sudut pengambilan ekstrem dari bawah membuat kaki tampak lebih panjang dan tubuh lebih tinggi, ciri yang biasanya dimiliki APBT. Harness juga menutupi bagian dada.
8	american_pit_bull_terrier_32.jpg / APBT	SBT (72,1%)	Foto dari foto cetak (ada bingkai putih), hanya bagian kepala yang terlihat, dan warnanya bergeser. Distribusinya berbeda dari foto biasa di train set.

Sebagian besar kesalahan terjadi karena ciri pembeda kedua ras memang tidak terlihat pada foto, seperti ukuran tubuh, kaki, atau pola bulu. Yang perlu diwaspadai adalah confidence yang sangat tinggi (di atas 98%) pada kesalahan No. 1 dan 2. Ini menunjukkan model cenderung overconfident, sehingga confidence score saja tidak cukup untuk menyaring prediksi yang salah.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Untuk skenario data terbatas seperti ini (sekitar 140 citra train per kelas), strategi yang direkomendasikan adalah model pretrained yang di-fine-tune hanya pada blok terakhir, dengan differential learning rate dan early stopping, seperti B3/B4. Bila memungkinkan, gunakan arsitektur efisien seperti EfficientNet-B0: B5 menghasilkan Macro F1 tertinggi (94,95%, sekitar 4,5 poin di atas ResNet-18 terbaik) dengan total parameter 4,0 juta dibanding 11,2 juta dan waktu training sekitar 2 menit (Slide 24). Kondisi berlakunya:

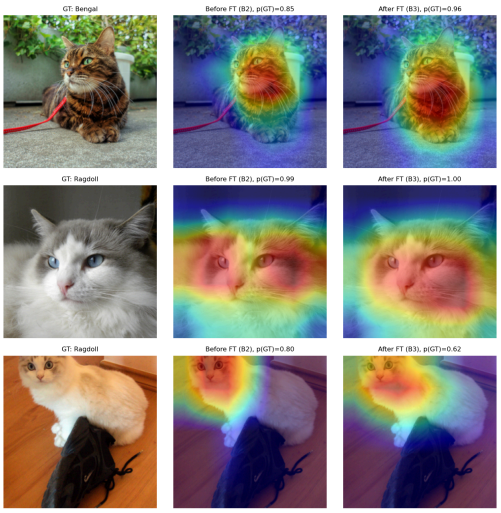
- Fine-tuning bertahap (B3/B4/B5): bila tersedia GPU, validation set yang representatif untuk early stopping, dan setidaknya ratusan citra per kelas.
- Feature extraction (B2): bila data jauh lebih sedikit, model sering dilatih ulang dengan biaya rendah, backbone dipakai bersama untuk beberapa tugas, atau tidak ada validation set yang andal.
- Training dari nol (B1) tidak disarankan untuk volume data seperti ini.
- Augmentasi layak dipasang sebagai pengaman, tetapi jangan mengharapkan kenaikan akurasi besar bila sudah ada early stopping dan backbone sebagian beku. Hindari transformasi yang mengubah ciri label, seperti hue shift.

Batasan studi ini:

- Satu seed (42). Dengan 299 citra test, satu citra setara 0,33 poin, sehingga selisih B2, B3, dan B4 (di bawah 1,5 poin) belum dapat dianggap signifikan.
- Hanya 10 kelas dengan dua pasangan ras yang sengaja dipilih mirip, sehingga hasilnya belum tentu berlaku untuk 37 kelas.
- Tanpa tuning hyperparameter (learning rate tetap, tanpa scheduler atau warmup); B1 kemungkinan paling dirugikan.
- B4 hanya diuji pada konfigurasi B3, dan B5 hanya diuji dengan satu konfigurasi.
- Waktu training diukur di Google Colab (Tesla T4) yang dapat bervariasi antar sesi, dan latency inference tidak diukur.

C5. Eksplorasi Tambahan: Grad-CAM pada layer4

Grad-CAM [8] dihitung pada layer4 terhadap kelas ground truth, dengan membandingkan B2 (layer4 masih berisi bobot ImageNet asli) dan B3 (layer4 sudah di-fine-tune). Kedua model memakai head 10 kelas sehingga hasilnya sebanding. Gambar 3 menampilkan tiga citra test yang dianalisis.



Gambar 3. Grad-CAM layer4 sebelum (B2) dan sesudah (B3) fine-tuning

Pada Bengal, fokus sebelum fine-tuning ada di wajah dan kepala, sedangkan sesudahnya bergeser ke dada dan badan yang memiliki pola bulu, dan probabilitas kelas benar naik dari 0,85 ke 0,96. Pola bulu memang ciri utama Bengal, sehingga pergeseran ini masuk akal. Pada Ragdoll pertama, heatmap menjadi lebih menyatu di area wajah (0,99 menjadi 1,00). Pada Ragdoll kedua, heatmap sesudah fine-tuning justru lebih rapat di sekitar wajah bagian bawah, tetapi probabilitasnya turun dari 0,80 ke 0,62. Artinya, area perhatian yang lebih terfokus tidak selalu menghasilkan prediksi yang lebih yakin.

Pergeseran bobot layer4 dari bobot ImageNet juga diukur dengan relative change $\|W_{ft} - W_{pre}\| / \|W_{pre}\|$. Perubahannya kecil, yaitu 3,3% sampai 10,3%. Pergeseran terbesar ada di convolution paling akhir (layer4.1.conv2, 10,3%) dan terkecil di downsample (3,3%). Ini sejalan dengan best practice pada Slide 29: layer paling akhir menyimpan fitur yang paling spesifik sehingga paling banyak disesuaikan, sementara learning rate kecil (1e-4) menjaga bobot tetap dekat dengan titik pretrained sehingga tidak terjadi catastrophic forgetting.

Pernyataan Penggunaan AI

Dalam pengerjaan tugas ini saya menggunakan alat bantu AI generatif. Rinciannya sebagai berikut.

Alat yang digunakan

- Claude Opus 5.5 dan Claude Sonnet 5.5 (Anthropic).

Bentuk bantuan

- Kode notebook: kerangka training loop, penambahan dan perbaikan comment, logging, atau visualisasi.
- Bagian A: Claude digunakan untuk membantu menyusun catatan belajar. Claude digunakan untuk memparafrasekan draf jawaban yang saya tulis, tanpa menambah substansi baru.
- Bagian C: Saya menulis draf C dan Claude digunakan untuk memberi saran dan struktur urutan bagian saya, mengklarifikasi konsep, dan melakukan parafrase agar struktur tulisan, tanpa menambah substansi baru.
- Review: Claude digunakan untuk memeriksa kesesuaian angka laporan dengan log dan memberi masukan revisi, antara lain perbaikan referensi, rujukan slide, dan deskripsi Gambar 3.

Cara verifikasi

- Mencocokkan setiap angka pada Tabel 1 dan pembahasan dengan results_summary.csv dan log per epoch
- Menjalankan ulang notebook dari awal dengan seed 42
- Memeriksa sendiri kedelapan citra di C3 dan Grad-CAM di C5 sebelum menerima hipotesisnya
- Mencocokkan setiap referensi dengan sumber aslinya

Referensi

[1] K. He, X. Zhang, S. Ren, and J. Sun, “Identity mappings in deep residual networks,” in *Proc. European Conf. Computer Vision (ECCV)*, 2016, pp. 630–645.

[2] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[3] A. Kumar, A. Raghunathan, R. Jones, T. Ma, and P. Liang, “Fine-tuning can distort pretrained features and underperform out-of-distribution,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2022.

[4] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How transferable are features in deep neural networks?” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 3320–3328.

[5] C. Shorten and T. M. Khoshgoftaar, “A survey on image data augmentation for deep learning,” *Journal of Big Data*, vol. 6, no. 60, 2019.

[6] J. Howard and S. Ruder, “Universal language model fine-tuning for text classification,” in *Proc. 56th Annu. Meeting of the Association for Computational Linguistics (ACL)*, 2018, pp. 328–339.

[7] J. Kirkpatrick et al., “Overcoming catastrophic forgetting in neural networks,” *Proc. National Academy of Sciences (PNAS)*, vol. 114, no. 13, pp. 3521–3526, 2017.

[8] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 618–626.